MACHINE LEARNING CANVAS

Designed for: **MiBici** Designed by: **Equipo 08** Date: 16/Oct/2026 Iteration: 1.

PREDICTION TASK

What is the type of task? Which entity are predictions made on? What are the possible outcomes to predict? When are outcomes observed?

P1: Regresión: Predecir viajes salientes por estación para la siguiente hora.

P2: Clasificación: Estimar riesgo de desabasto o saturación para la siguiente hora.

P3: Clustering: Agrupar estaciones según patrones de uso y ubicación.

DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

Planear distribución de bicicletas.

Priorizar rebalanceo de estaciones.

Identificar oportunidades de expansión y mejora.

Asignar recursos operativos de forma preventiva.

VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed? How will the ML solution integrate with their workflow, and through which user interfaces?

Anticipar la demanda futura.

Reducir problemas de disponibilidad.

Mejorar el rebalanceo de bicicletas.

Apoyar decisiones basadas en datos.

DATA COLLECTION

How are entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)? How is data updated continuously while controlling cost and maintaining freshness?

Descarga automática desde MiBici.

Normalización de esquemas históricos.

Conversión a formato Parquet.

Versionado mediante hashes y manifiesto.

Proceso reproducible ejecutable desde terminal.

DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

Viajes: origen, destino, fecha y hora.

Estaciones: ID, capacidad y coordenadas.

Fuente: portal de datos abiertos de MiBici.

Outcomes: demanda, riesgo y patrones de uso.

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions? Which data is used to simulate pre-deployment impact? What are the criteria for deployment? Are there fairness constraints?

Beneficio: mejor planeación, rebalanceo y expansión.

Costo: rebalanceos innecesarios y estaciones sin servicio.

Simulación con viajes históricos y datos de estaciones.

Despliegue si supera al baseline y es reproducible.

Monitoreo de posibles sesgos geográficos.

MAKING PREDICTIONS

Are predictions made in batch or in real time? How frequently? How much time is available for this (including featurization and decisions)? Which computational resources are used?

Batch (no tiempo real)

Actualización con nuevas ingestas

Horizonte corto (P1-P2)

Clustering periódico (P3)

Python + Scikit-Learn + MLflow

BUILDING MODELS

How many models are needed in production? When should they be updated? How much time is available for this (including featurization and analysis)? Which computation resources are used?

3 modelos (P1, P2, P3)

Reentrenamiento con nuevos datos

Baselines + modelos avanzados

Random Forest, LightGBM, XGBoost, DBSCAN

CPU local / Colab / GitHub Actions

FEATURES

What representations are used for entities at prediction time? What aggregations or transformations are applied to raw data sources?

P1: hora, día, estación y demanda histórica.

P2: entradas, salidas, balance y capacidad.

P3: perfiles horarios, duración y ubicación.

Agregaciones temporales y variables derivadas.

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business? How often should they be reviewed?

MAE (P1), Recall/F1 (P2), Silhouette (P3).

Drift de demanda y uso.

Seguimiento en MLflow.

Revisión semanal.

Reentrenamiento según necesidad.